# Các vai trò nghiên cứu và Related Work trong Long-CoT — Bản thảo mở rộng

Ngày 8 tháng 11 năm 2026

**Tóm tắt nội dung**

Bản thảo tổng hợp các nghiên cứu về suy luận Long Chain-of-Thought (Long-CoT) trong mô hình ngôn ngữ lớn. Chúng tôi tổ chức 24 công trình tiêu biểu thành 15 nhóm phương pháp thuộc bốn vai trò nghiên cứu: A1 (Training/Data), A2 (Inference/Control), A3 (Analysis) và A4 (Evaluation/Benchmark). Chín survey được đối chiếu theo phạm vi và đơn vị phân loại, từ đó làm rõ mối liên hệ với cách gán vai trò nghiên cứu. Ngoài phương pháp và kết quả, bản tổng hợp phân tích các đánh đổi trong training và inference, cấp bằng chứng phân tích, đơn vị đánh giá, sampling và cách tính compute của toàn hệ thống. Tám câu hỏi nghiên cứu đề xuất kết nối các vai trò này với thiết kế thực nghiệm cụ thể. Danh mục ưu tiên nghiên cứu trực tiếp Long-CoT, đồng thời đánh dấu các công trình liên quan và nền tảng; đây là tập chọn lọc, các thí nghiệm được trích dẫn chưa được nhóm tái lập độc lập.

## 1 Related Work và đối chiếu taxonomy

Sự phát triển của reasoning model đã dẫn đến nhiều survey tổ chức literature theo khung nhận thức, search, compute scaling, evaluation và efficiency. Chúng tôi đối chiếu chín survey tiêu biểu [4, 8, 12, 15, 21, 22, 25, 31, 33] với bốn vai trò nghiên cứu: **A1 Training/Data**, **A2 Inference/Control**, **A3 Analysis** và **A4 Evaluation/Benchmark**. Trích dẫn được ghim theo phiên bản preprint; năm xuất bản hoặc taxonomy của bản mới hơn có thể khác. Đây là đối chiếu chọn lọc, không xác lập tính tiên phong so với mọi survey trước.

### 1.1 Nguyên tắc tổ chức của các survey trước

Các survey tiếp cận literature từ những góc nhìn kỹ thuật bổ sung cho nhau, được tổng hợp trong Bảng 1.

**Reflection và exploration.** Chen và cộng sự [4] tổ chức theo ba năng lực: *Deep Reasoning* (thiết kế định dạng và cách training), *Feasible Reflection* (*Feedback* để nhận diện lỗi và *Refinement* để điều chỉnh trajectory), *Extensive Exploration* (inference scaling qua deliberation nội tại và tương tác công cụ bên ngoài). Tách feedback khỏi refinement giúp phân biệt việc tìm được lỗi với việc thực sự sinh ra bản sửa hợp lệ.

**Chuyển đổi theo khung dual-process.** Li và cộng sự [15] đặt suy luận trong khung chuyển đổi từ System 1 sang System 2, với ba chiều liên hệ nhau: *Features* mô tả hành vi đầu ra và mẫu suy luận quan sát được; *Methods* gồm Structure Search, Reward Modeling, Self Improvement, Macro Action và Reinforced Fine-Tuning (RFT); *Evolution* mô tả tiến trình từ sinh đáp án trực giác đến inference có deliberation.

**Test-Time Scaling đa chiều (4W).** Zhang và cộng sự [31] tổ chức test-time compute scaling theo bốn câu hỏi:

1. **What to scale**: Parallel sampling như Best-of-$N$, self-consistency; sequential refinement như sửa lặp, budget forcing; hybrid search; và internal scaling, tức phân bổ compute do model học qua training.
2. **How to scale**: Tuning-based như RL, process supervision; đối chiếu với inference-based prompting và search scaffolding.
3. **Where to scale**: *Reasoning-intensive Tasks* như toán và logic hình thức; *Agentic Tasks* như dùng công cụ và planning nhiều bước; *Others* như hỏi đáp tổng quát và tác vụ chuyên miền.
4. **How well to scale**: *Performance* như accuracy, pass@$k$; *Efficiency* như token budget, compute cost; *Controllability* như tuân thủ budget, hành vi dừng; *Scalability* như số mũ bão hòa thực nghiệm và giới hạn scaling. §8.2 còn thảo luận tiêu chuẩn kết thúc và khó khăn khi phân biệt độ dài trajectory với logical sufficiency.

**Inference dưới góc nhìn search.** Wei và cộng sự [25] tổ chức phương pháp theo *Node Representation and Granularity*, gồm *Trace-based*, *State–Action* và *Terminal-State*; *Evaluation Function*, gồm value network, process reward model, self-evaluation; *MCTS Dynamics*, gồm selection, expansion, simulation, backpropagation; cùng giao thức báo cáo compute.

**Đánh giá trace từng bước.** Lee và Hockenmaier [12] tập trung vào các bước suy luận trung gian, với bốn chiều: *Factuality* là độ đúng dữ kiện của tiền đề; *Validity* là quan hệ suy ra logic giữa các bước; *Coherence* là tổ chức và tính mạch lạc diễn ngôn; *Utility* là đóng góp cho lời giải cuối. Evaluator được chia thành rule-based, intrinsic model-based và external judge, kèm benchmark meta-evaluation.

**Phân bổ compute cho deliberation.** Ji và cộng sự [8] đối chiếu *System-1 adaptation*, gồm thay đổi model, input, representation và phân phối output token, với *System-2 deliberate reasoning*, gồm external feedback loop, tree/graph search policy và compute budgeting thích ứng.

**Reasoning hiệu quả và thích ứng.** Qu và cộng sự [21] tổ chức theo inference, SFT, RL và pretraining; inference gồm length budgeting, system/model switching và parallel search. Sui và cộng sự [22] chia theo nơi can thiệp: model, reasoning output hoặc input prompt. Zhu và Li [33] tách prompting, pipeline, decoding và merging không cần training khỏi fine-tuning và RL có training. Phạm vi được tác giả nêu loại trừ general model compression, tối ưu kiến trúc và multimodal efficiency. Các survey cho thấy việc rút ngắn và thích ứng reasoning đã được khảo sát đáng kể; cách gán research role của nhóm bổ sung cho các trục lifecycle, nơi can thiệp và nhu cầu training này.

## 1.2 Taxonomy đang phân loại đối tượng nào?

Các survey có đơn vị tổ chức khác nhau. Taxonomy theo capability hỏi hành vi suy luận nào được hỗ trợ; taxonomy theo lifecycle hỏi can thiệp xảy ra ở giai đoạn nào; taxonomy về search mô tả cấu trúc tính toán; taxonomy evaluation tách tiêu chí khỏi cách hiện thực evaluator. Chỉ so tên nhánh cao nhất có thể phóng đại khác biệt hoặc che khuất phần giao nhau đáng kể.

| Survey | Phạm vi và trục tổ chức | Giá trị đối chiếu |
|---|---|---|
| **Chen và cộng sự** (2025) [4] | **Deep Reasoning**: Format, Learning. **Feasible Reflection**: Feedback, Refinement. **Extensive Exploration**: Scaling, Internal, External. | Tách nhận diện lỗi (*Feedback*) khỏi điều chỉnh trajectory (*Refinement*). |
| **Li và cộng sự** (2025) [15] | **System 2 Blueprint**: Features, Methods, Evolution. **Phương pháp**: Structure Search, Reward Modeling, Self Improvement, Macro Action, RFT. | Liên hệ mẫu hành vi quan sát được với kỹ thuật training và search. |
| **Zhang và cộng sự** (2025) [31] | **What**: Parallel, Sequential, Hybrid, Internal. **How**: Tuning-based, Inference-based. **Where**: Reasoning-intensive, Agentic, Others. **How Well**: Performance, Efficiency, Controllability, Scalability. | Taxonomy đa chiều kết nối miền tác vụ, compute budget và hiện tượng bão hòa scaling. |
| **Wei và cộng sự** (2026) [25] | **Cấu trúc search**: Node Representation (Trace-based, State–Action, Terminal-State), Evaluation Function, MCTS Dynamics, Compute Reporting. | Hệ thống hóa tree search, độ hạt của node và cơ chế credit assignment. |
| **Lee và Hockenmaier** (2025) [12] | **Tiêu chí**: Factuality, Validity, Coherence, Utility. **Evaluator**: Rule-based, Intrinsic, External; benchmark meta-evaluation. | Phân loại metric và kiến trúc verification cho trace suy luận từng bước. |
| **Ji và cộng sự** (2025) [8] | **Chuyển đổi nhận thức**: System-1 adaptation (model, input, representation, output) và System-2 deliberate reasoning (feedback, search). | Đối chiếu generation trực giác nhanh với deliberate search và đánh đổi compute budget. |
| **Qu và cộng sự** (2025) [21] | **Lifecycle**: Inference, SFT, RL, pretraining; các dạng inefficiency và hướng evaluation. | Nối phân bổ compute lúc inference (A2) với efficiency được học (A1). |
| **Sui và cộng sự** (2025) [22] | **Nơi can thiệp**: Model, reasoning output, input prompts; dữ liệu/compression và evaluation. | Tổ chức biện pháp giảm overthinking theo nơi can thiệp. |
| **Zhu và Li** (2025) [33] | **Nhu cầu training**: Training-free và training-based cho concise/adaptive thinking. | Tách control khi triển khai (A2) khỏi policy suy luận được học (A1). |

Bảng 1: Đối chiếu taxonomy của các survey về Long-CoT và test-time reasoning.

**Capability và đóng góp nghiên cứu.** Deep reasoning, reflection và exploration của Chen và cộng sự mô tả thuộc tính hoặc năng lực deliberation mở rộng [4]. Một paper có thể học năng lực đó, điều khiển nó lúc generation, phân tích khi nào nó xuất hiện hoặc xây benchmark đo nó. Những đóng góp này thuộc các research role khác nhau nhưng vẫn dùng chung nhãn capability. Feedback và refinement đặc biệt hữu ích: nhận ra lỗi, sinh bản sửa hiệu quả và đo chất lượng bản sửa là ba đóng góp riêng.

Features, methods và evolution trong Li và cộng sự cung cấp bức tranh rộng hơn về reasoning model [15]. Khung System 1–2 tổ chức literature, tự nó chưa chứng minh model triển khai cơ chế nhận thức của con người. Tương tự, phạm vi adaptation của Ji và cộng sự bao gồm test-time method ngoài explicit long reasoning trace [8]. Có thể dùng các khung này để đặt adjacent work vào bối cảnh mà không coi mọi phương pháp là bằng chứng trực tiếp về Long-CoT.

**Trục compute và cấu trúc thực thi.** Bốn câu hỏi của Zhang và cộng sự có thể gán nhiều mô tả cho cùng nghiên cứu: dạng compute, cách hiện thực, miền tác vụ và tiêu chí đánh giá [31]. Parallel sampling có thể tăng compute mà không kéo dài từng trace. Wei và cộng sự bổ sung độ hạt của search node và cơ chế evaluator [25]; node là cả lời giải trong phương pháp này không tương đương một bước suy luận nguyên tử trong phương pháp khác. Cần giữ rõ các đơn vị trước khi so depth, rollout count hoặc efficiency.

**Tiêu chí đánh giá và loại evaluator.** Factuality, validity, coherence và utility của Lee và Hockenmaier xác định *đánh giá điều gì*; rule-based, intrinsic và external evaluator xác định *đánh giá bằng cách nào* [12]. Một tiêu chí có thể được hiện thực bằng nhiều evaluator. Trace trôi chảy chưa chắc valid; bước valid chưa chắc useful; reasoning hữu ích nhìn thấy được chưa chắc bộc lộ mọi yếu tố ảnh hưởng đáp án. Vì vậy phần A3/A4 tách process quality khỏi faithfulness.

**Lifecycle, nơi can thiệp và nhu cầu training.** Các survey efficiency bổ sung cho nhau. Qu và cộng sự chia theo inference, SFT, RL, pretraining; Sui và cộng sự chia theo model, reasoning output, input prompt; Zhu và Li chia theo training-free và training-based [21, 22, 33]. Một pipeline có thể thay nhiều thành phần, gồm cả phần đã học và phần chạy lúc inference. Training-free không có nghĩa không cần auxiliary module, calibration hay runtime cost. Phạm vi loại trừ được survey nêu rõ cần được ghi nhận như lựa chọn của tác giả, thay vì xem là thiếu sót đã được chứng minh.

### 1.3 Liên hệ với Research Role A1–A4

Khung bốn vai trò phân loại đóng góp kỹ thuật trung tâm: **A1 Training/Data** bao quát objective và dữ liệu; **A2 Inference/Control** bao quát thực thi và search control; **A3 Analysis** bao quát giải thích và chẩn đoán; **A4 Evaluation/Benchmark** bao quát công cụ và giao thức đánh giá. Các vai trò giữ lại mô tả hữu ích từ survey trước thay vì thay thế chúng. Mỗi paper có một bản ghi chính cùng secondary role, giúp thể hiện giao thoa mà không tăng giả số lượng literature.

**Ví dụ crosswalk cụ thể.** s1 được gán A1 vì quy trình SFT với dữ liệu chọn lọc là đóng góp trung tâm; budget forcing được giữ ở A2 [19]. Có thể mô tả thêm bằng sequential scaling và tuning/decoding trong các khung survey trước. TAAR có primary A2 cho adaptive restart, secondary A3 cho chẩn đoán thinking trap [3]. CoTJudger có primary A4 cho evaluator, đồng thời graph analysis cung cấp bằng chứng cho A3 [14]. Đây là cách gán của nhóm, không khẳng định mọi survey trước đã gán các paper như vậy.

Trọng tâm đề xuất là nối cách học reasoning, cách điều khiển, những gì phân tích thực nghiệm giải thích được và bằng chứng evaluation hỗ trợ. Đây là lựa chọn tổng hợp, không phải khẳng định survey trước bỏ qua analysis hoặc evaluation. So sánh cần ghi riêng final-answer

accuracy, process quality, efficiency và faithfulness, cùng model, split, sampling và compute budget. Giảm token tự nó không đo được latency toàn hệ thống hay chứng minh causal faithfulness.

### 1.4 Giới hạn và định vị bản tổng hợp

**Chọn và trích xuất nghiên cứu.** Danh mục ưu tiên nghiên cứu trực tiếp deliberation mở rộng, giữ adjacent hoặc foundational work khi chúng làm rõ phương pháp, failure mode hay giao thức evaluation. Mỗi công trình có nguồn ghim phiên bản, bài toán, phương pháp, kết quả tác giả báo cáo, đóng góp và giới hạn. Từ khóa tìm kiếm và mở rộng theo trích dẫn được dùng để chọn hướng tiêu biểu; đây không phải quy trình systematic review đầy đủ và không bảo đảm coverage toàn bộ. Cập nhật model, venue hoặc dataset về sau có thể cần bản ghi phiên bản riêng.

**Diễn giải khoảng trống nghiên cứu.** Đối chiếu gợi ra câu hỏi về đánh đổi objective, tín hiệu và action của controller, cấp bằng chứng phân tích và đơn vị evaluation. Đây là cơ hội tổ chức bản thảo, chưa chứng minh survey trước bỏ qua chúng. Muốn tuyên bố novelty mạnh hơn, như survey đầu tiên bao quát đủ bốn vai trò, cần corpus survey rộng hơn và tiêu chí coverage tường minh. Vì vậy đóng góp được định vị là tổng hợp theo research role có chú ý cấp bằng chứng, kèm danh mục paper tái sử dụng được.

**Cách sử dụng bản tổng hợp.** Phần sau trình bày phương pháp tiêu biểu, đối chiếu giả định và phép đo, rồi đề xuất câu hỏi nghiên cứu liên vai trò có thể kiểm chứng. Danh mục tách kết quả tác giả khỏi diễn giải so sánh của nhóm. Nhờ đó repo có thể tiếp nhận bằng chứng mới, kể cả kết quả âm hoặc mâu thuẫn, mà không coi ranh giới subgroup hiện tại là bất biến.

| **Góc nhìn survey** | **Đơn vị tổ chức chính** | **Câu hỏi giữ lại trong A1–A4** |
|---|---|---|
| Chen và cộng sự | Capability của Long-CoT | Đóng góp là học, điều khiển, giải thích hay đo capability đó? |
| Li và cộng sự | Features, methods, evolution | Bằng chứng nói về thuật toán, hành vi hay quy trình phát triển? |
| Zhang và cộng sự | What, how, where, how well | Tài nguyên, cách hiện thực, tác vụ và budget đánh giá là gì? |
| Wei và cộng sự | Node, evaluator, search dynamics | Một search step là gì; feedback đổi thực thi thế nào? |
| Lee và Hockenmaier | Tiêu chí và loại evaluator | Đo thuộc tính nào; evaluator được kiểm tra ra sao? |
| Ji và cộng sự | Adaptation và deliberate reasoning | Bằng chứng trực tiếp Long-CoT hay bối cảnh compute rộng hơn? |
| Qu và cộng sự | Giai đoạn lifecycle | Chi phí giảm tổng thể hay chuyển giữa training và inference? |
| Sui và cộng sự | Nơi can thiệp | Input, model, output hay nhiều thành phần cùng thay đổi? |
| Zhu và Li | Nhu cầu training | Phần nào học trước, phần nào thích ứng khi sử dụng? |

Bảng 2: Crosswalk do nhóm đề xuất giữa đơn vị tổ chức của survey và câu hỏi theo research role. Đây không phải điểm coverage nhị phân hay khẳng định từng survey tự gán những nhãn này.

## 2 Các vai trò nghiên cứu trong Long-CoT

Để tổ chức literature về suy luận Long Chain-of-Thought (Long-CoT), chúng tôi chia các hướng nghiên cứu thành bốn trục kỹ thuật chính:

1. **A1: Training/Data**—mục tiêu tối ưu, quy trình reinforcement learning (RL), tuyển chọn dữ liệu theo curriculum và các pipeline distillation;
2. **A2: Inference/Control**—early stopping thích ứng, điều hướng cây tìm kiếm, thoát bẫy suy luận và cô lập context theo mô-đun;
3. **A3: Analysis**—mô hình hóa cấu trúc diễn ngôn, kiểm tra nhân quả bằng can thiệp phản thực, giới hạn scaling theo độ phức tạp tổ hợp và hành vi overthinking;
4. **A4: Evaluation/Benchmark**—bài toán mang trạng thái qua horizon dài, chỉ số redundancy dựa trên graph và giao thức process supervision.

Các vai trò này là góc nhìn về đóng góp kỹ thuật, không phải những loại model loại trừ nhau. Một công trình có thể liên quan nhiều vai trò; chúng tôi gán *primary role* theo đóng góp trung tâm và dùng *secondary roles* để ghi nhận phần giao thoa. Các subgroup là cách tổ chức được nhóm đề xuất từ những phương pháp đã có, nhằm làm rõ các hướng nghiên cứu khác nhau.

**Phạm vi và quy tắc gán vai trò.** Long-CoT ở đây chỉ quá trình deliberation mở rộng, có exploration hoặc verification; không áp dụng một ngưỡng token chung. Chỉ có đầu vào long-context chưa đủ để thuộc phạm vi này. A1 thay đổi dữ liệu training hoặc tham số model; A2 thay đổi cách thực thi inference; A3 chủ yếu khảo sát một hiện tượng; A4 chủ yếu cung cấp công cụ hoặc giao thức đánh giá. Danh mục gồm 24 công trình, phân bố 6/5/8/5 theo primary role: 19 nghiên cứu trực tiếp Long-CoT, bốn công trình suy luận liên quan và một công trình nền tảng về phương pháp kiểm tra faithfulness. Dẫn chéo không được tính thành paper bổ sung. Đây là bản tổng hợp chọn lọc, không phải systematic review đầy đủ; kết quả được báo cáo chưa được nhóm tái lập độc lập.

### 2.1 Training/Data (A1)

A1 nghiên cứu cách hình thành năng lực deliberation qua horizon dài trong post-training, từ pure RL đến giám sát dựa trên tập dữ liệu nhỏ được chọn kỹ và pipeline curriculum nhiều giai đoạn.

#### 2.1.1 Hình thành và mở rộng Long-CoT bằng RL

Một hướng quan trọng khảo sát khả năng hình thành hành vi suy luận phức tạp trực tiếp từ RL quy mô lớn với rule-based verification. Trong **DeepSeek-R1-Zero** [6], policy được tối ưu trực tiếp từ `DeepSeek-V3-Base` bằng Group Relative Policy Optimization (GRPO). Thuật toán tính advantage trong nhóm output được lấy mẫu mà không cần critic network riêng:

$$A_i = \frac{r_i - \text{mean}(\{r_j\})}{\text{std}(\{r_j\}) + \epsilon}, \tag{1}$$

trong đó reward $r_i$ phản ánh độ đúng đáp án và định dạng tag. Trong thiết lập này, DeepSeek-R1-Zero tự hình thành self-verification và các trajectory exploration mở rộng, đạt 77.9% Pass@1 trên AIME 2024 và 95.9% trên MATH-500. Tuy nhiên, tác giả ghi nhận hiện tượng trộn ngôn ngữ và khó đọc. Để xử lý, **DeepSeek-R1** hoàn chỉnh sử dụng cold-start SFT với vài nghìn trace được chọn lọc, reasoning RL, rejection sampling tạo tập dữ liệu tổng hợp 800k mẫu và RL căn chỉnh đa tác vụ. Model đạt 79.8% trên AIME 2024 (671B MoE); SFT distillation cũng chuyển giao hiệu quả sang dense model nhỏ hơn, với 72.6% trên Qwen-32B.

**Kimi k1.5** [10] mở rộng context training đến 128k token cho cả văn bản và thị giác. Phương pháp dùng Online Policy Mirror Descent với relative entropy regularization, policy không có value head và gradient âm từ rollout sai. Để chấm các trajectory dài, tác giả huấn luyện Chain-of-Thought Reward Model (CoT-RM) trên 800k mẫu: model sinh rationale trước khi phán quyết độ đúng đáp án cuối ở dạng JSON. Accuracy trên mẫu spot-check thủ công do tác giả báo cáo khoảng 98.5%, so với khoảng 84.4% của outcome reward model truyền thống; Kimi k1.5 đạt 77.5% Pass@1 trên AIME 2024. Khung *Long2short* dùng shortest-path rejection sampling và preference optimization có length penalty để chuyển tri thức từ suy luận dài sang trace ngắn hơn, nhằm giảm latency lúc inference.

### 2.1.2 SFT với tập dữ liệu nhỏ được chọn lọc

Khác với RL hoặc distillation corpus quy mô lớn, hướng data-centric khảo sát liệu một tập demonstration nhỏ nhưng chất lượng cao có đủ để kích hoạt năng lực suy luận trên base model mạnh. **s1** [19] xây dựng `s1K`, gồm 1,000 bài khó với reasoning trace được distill từ `gemini-2.0-flash-thinking-exp-1219`.

Fine-tune `Qwen2.5-32B-Instruct` trên s1K đạt 50.0% Pass@1 trên AIME 2024 với greedy decoding thông thường. Khi kết hợp *budget forcing*—chặn delimiter `</thought>` và nối thêm "Wait"—kết quả đạt 56.7% trên AIME 2024 và 59.6% trên GPQA Diamond. Đây là bằng chứng về sample efficiency của tập dữ liệu được chọn lọc, trong điều kiện năng lực sẵn có của base model.

**LIMO** [29] chọn 817 mẫu theo độ khó câu hỏi và rubric bốn chiều của trace: lập luận chi tiết, self-verification, exploration và độ hạt thích ứng. SFT trên `Qwen2.5-32B-Instruct` đạt 63.3% Pass@1 trên AIME 2024 và 95.6% trên MATH-500. Tuy nhiên, khi chuyển cùng quy trình tối giản sang `Qwen1.5-32B-Chat`, accuracy trên AIME giảm còn 9.2%, thấp hơn 54.1 điểm phần trăm. Kết quả cho thấy hiệu quả dữ liệu phụ thuộc chặt vào base model cụ thể được thử nghiệm.

### 2.1.3 Pipeline curriculum nhiều giai đoạn

**Light-R1** [26] công bố quy trình có thể tái lập gồm ba stage training và model merging, khởi tạo từ `Qwen2.5-32B-Instruct` thay vì pretraining từ đầu. Pipeline gồm Stage 1 SFT trên 76k bài toán đã lọc với sequence length tối đa 20k token; Stage 2 SFT trên 3,000 bài thi đấu; semi-on-policy DPO với context 32k; và merging trong không gian trọng số. Accuracy của Light-R1-32B trên AIME 2024 tăng từ 16.6% (base) lên 69.0% (+SFT-1), 73.0% (+SFT-2), 75.8% (+DPO) và 76.6% (+Merging). GPQA lại biến động: 64.3% ở SFT-1, 60.6% ở SFT-2 và 61.8% sau merging. Tác giả còn kiểm tra decontamination và ghi nhận test-set leakage trong một số corpus reasoning mở trước đó.

### 2.1.4 RL hướng efficiency và học phân bổ compute

Arora và Zanette [1] tiếp tục training reasoning model bằng reward độ đúng kết hợp length penalty có thể điều chỉnh. Với distilled model 7B tại $\alpha = 0.2$, mức tiết kiệm token khác nhau rõ theo tác vụ: 83% trên GSM8K và 27% trên AIME 2024. Đây là đánh đổi efficiency–accuracy, không phải bảo đảm giữ nguyên accuracy trong các lần training hữu hạn. Compression cũng có thể làm giảm faithfulness đo được. Hướng này bổ sung cho RL tập trung vào capability bằng cách học khi nào deliberation mở rộng xứng đáng với chi phí.

## 2.2 Inference/Control (A2)

Các phương pháp inference control điều tiết compute budget trong generation, xử lý overthinking, sự bám giữ lỗi sớm và overhead của context qua horizon dài.

### 2.2.1 Early stopping thích ứng và đánh giá sufficiency

Long-CoT thường tiếp tục verification và thử cách giải khác sau khi đã đủ cơ sở kết luận. **DTSR** [27] xử lý mà không retraining: theo dõi reflection trigger như "Wait", "Alternative" để chọn checkpoint, rồi dùng metacognitive sufficiency check đánh giá phần suy luận hiện tại đã đủ để chốt đáp án chưa. Trên `Qwen3-14B`, DTSR giảm token từ 5,761 xuống 3,748 ($-34.9\%$), với accuracy 84.8% so với 84.4% của baseline. Tuy nhiên, trên `Qwen3-8B`, accuracy giảm 0.9 điểm phần trăm, từ 81.9% xuống 81.0%, đổi lấy mức giảm 32.0% token. Khả năng tự đánh giá sufficiency vì thế thay đổi theo quy mô model.

**REFRAIN** [23] xây dựng điều kiện dừng từ reflective redundancy. Bộ phân biệt kiểm tra giả thuyết đáp án đã có, reflection token và sentence embedding similarity vượt ngưỡng $\tau$; ngưỡng được điều chỉnh bằng Sliding-Window UCB bandit. Trên `gpt-oss-20B`, REFRAIN cải thiện Pass@1 ở các benchmark được thử: +2.73 điểm phần trăm GSM8K, +3.40 điểm phần trăm MATH-500 và +7.07 điểm phần trăm GPQA-Diamond, đồng thời giảm 33.3% đến 44.7% token.

### 2.2.2 Phát hiện bẫy và phục hồi thích ứng

Trong suy luận dài, một cam kết sai sớm có thể bám dai trong prefix, khiến self-correction ở cuối vẫn bị neo vào tiền đề sai. **TAAR** [3] ghi nhận 44.4% thinking trap được chẩn đoán xuất hiện trong 20% đầu sequence. Phương pháp huấn luyện diagnostic policy $\pi_\phi$ dự đoán vị trí bẫy và xác suất thoát; *Cut@Trap* cắt trajectory trước đoạn bẫy rồi restart với temperature thích ứng. Với cùng path budget được báo cáo $K = 4$ trên `DeepSeek-R1-Distill-Qwen-8B`, accuracy trung bình trên năm benchmark thi đấu tăng từ 64.5% (Avg@4) và 66.0% (PRM@4) lên 69.1%; Cut@Trap có escape rate 16.5%. Trên `GPT-OSS-120B`, kết quả lại giảm nhẹ từ 80.6% xuống 79.2%: model mạnh gặp ít bẫy hơn, trong khi pruning mạnh có nguy cơ bỏ prefix gần đúng.

Ở độ hạt lớn hơn, **MCTSr** [30] kết hợp Monte Carlo Tree Search với self-refinement bằng ngôn ngữ tự nhiên; mỗi node là một lời giải toán hoàn chỉnh. Dùng quy tắc UCT được sửa đổi, phương pháp sinh critique, viết lại lời giải và cập nhật value qua self-evaluation. Trên `LLaMA-3-8B`, search với 8 rollout tăng accuracy MATH từ 24.36% (zero-shot) lên 58.24%; ở Level 5, kết quả tăng từ 7.10% lên 34.06%.

### 2.2.3 Cô lập context và quản lý trạng thái

Autoregressive generation trên một flat context có attention cost bậc hai $O(T^2)$ và nguy cơ pha loãng context khi sequence dài. **Recursive Models** [28] tổ chức subtask trong các stack frame độc lập bằng tag `<call>` và `<return>`. Khi subtask hoàn thành, chỉ return value ngắn được chuyển về caller; token trung gian được loại khỏi active context. Trên SAT, model đệ quy fine-tune từ `Qwen2.5-3B-Instruct` đạt 98% (Easy), 95% (Medium) và 64% (Hard OOD), vượt flat CoT baseline. Trên sinh trace cờ Go 4x4 với length-OOD, model giữ 38.5% trace accuracy, trong khi flat CoT còn 1.0%.

### 2.2.4 Budget forcing và điều khiển độ sâu exploration

Hai cơ chế giao thoa bổ sung cho early stopping: budget forcing của s1 [19] điều tiết độ dài deliberation, còn TIP [24] hạn chế đổi hướng suy nghĩ quá sớm bằng penalty lên logits của transition token trong một cửa sổ decoding. Chúng nhắm vào hai lỗi phân bổ khác nhau: tiếp tục sau khi đã đủ lời giải và bỏ một nhánh triển vọng trước khi khám phá đủ sâu. Các bản ghi primary role vẫn lần lượt nằm ở A1 và A3.

## 2.3 Analysis (A3)

Các nghiên cứu phân tích khảo sát hành vi suy luận, từ cấu trúc diễn ngôn và quan hệ nhân quả nội tại đến graph mô tả failure mode và giới hạn độ phức tạp tổ hợp.

### 2.3.1 Cấu trúc diễn ngôn và quan hệ nhân quả nội tại

Một câu hỏi nền tảng là quan hệ diễn ngôn nhìn thấy trong trace có phản ánh dependency của tính toán nội tại hay không. **ReasoningFlow** [13] biểu diễn trace bằng Directed Acyclic Graph (DAG), với các cạnh định kiểu *support, attack, verify, assumption*. Để kiểm tra dependency nhân quả, tác giả dùng *Thought Anchors*, đo log KL-divergence của dự đoán bước $s_j$ khi attention đến bước $s_i$ bị mask. Trên QwQ và AIME, điểm Thought Anchors dự đoán cạnh ReasoningFlow có precision-recall tương đương heuristic chọn node gần theo khoảng cách token; mức alignment vì thế hạn chế trong thiết lập đã thử. Trong phân tích hành vi trace (Hình 5), local verification kèm sửa lỗi có step accuracy 84%, so với 64% ở bước lỗi trước đó; bước đã sửa có tỷ lệ dẫn đến đáp án cuối đúng 20% so với 5%. Đây là liên hệ quan sát trên trace, không phải can thiệp nhân quả độc lập có đối chứng.

**Lanham và cộng sự** [11] khảo sát faithfulness trên model đến 175B tham số bằng early answering, chèn lỗi và filler token. Trong §2.5.1 và Hình 5, thay CoT bằng filler không mang thông tin (“ ...”) không tăng task accuracy trên các benchmark được đánh giá. Accuracy giảm nhẹ ở TruthfulQA và OpenBookQA; tác giả nêu out-of-distribution effect như một cách giải thích có thể. Trong các model và tác vụ này, chỉ tăng test-time token mà không có nội dung ngữ nghĩa hữu ích không đem lại lợi ích reasoning; không thể khái quát thành quy luật cho mọi kiến trúc latent-compute.

### 2.3.2 Biểu diễn graph và chẩn đoán failure mode

Vượt ra ngoài chỉ số sequence tuyến tính, **CoT2Graph** [2] dùng typed dependency graph và Graph Neural Network (GNN), kết hợp GNNExplainer để nhận diện dấu hiệu cấu trúc. Tác giả quan sát trace đúng thường dựa vào strategic planning sớm, còn trace sai có synthesis node quá tải và dependency chưa được đáp ứng. Attribution này giải thích GNN predictor, không phải cơ chế nhân quả của LLM. Trên GPQA với trace `DS-Qw14B`, accuracy dự đoán đáp án cuối đúng/sai đạt 65.4%, cao hơn 7.8 điểm phần trăm so với Logistic Regression theo độ dài (57.6%) và 2.5 điểm phần trăm so với tree baseline LCoT2Tree (62.9%) ở Bảng 1. Trong Best-of-$N$ ($N = 5$) trên 600 câu MMLU-Pro của `DS-Qw7B`, selection bằng CoT2Graph đạt 54.5%, so với ORM-Best 50.8%, ORM + uncertainty 51.6% và mean baseline 43.2%; kết hợp entropy đạt 56.1%.

Feng và cộng sự [7] so sánh mười reasoning model và xác định *Failed-Step Fraction* (FSF) dự đoán correctness nhất quán hơn length hoặc review ratio. Selection theo FSF và can thiệp loại nhánh bị bỏ dở hỗ trợ control dựa trên cấu trúc. Tuy nhiên, graph phụ thuộc judge, và một nhánh bị bỏ dở không nhất thiết chứa bước sai logic.

### 2.3.3 Giới hạn scaling theo độ phức tạp tổ hợp

**ZebraLogic** [16] đánh giá suy luận suy diễn qua câu đố lưới Constraint Satisfaction Problem (CSP), với search space từ $< 10^3$ đến $> 10^9$ ứng viên. Tác giả ghi nhận *Curse of Complexity*: accuracy giảm mạnh khi search space vượt $10^6$. Parameter scaling không vượt được rào cản này: `Llama-3.1-405B` đạt 32.6% tổng thể nhưng còn 1.5% ở Large và 0.0% ở X-Large. Reasoning model tốt hơn ở độ khó vừa vẫn suy giảm mạnh ở X-Large: `o1-full` 42.5%, `DeepSeek-R1` 28.5%, `o1-mini` 12.0%. Repeated sampling (Best-of-$N$) và self-refinement chỉ đem lại cải thiện hạn chế khi độ phức tạp tổ hợp cao.

### 2.3.4 Overthinking, underthinking và self-doubt

Chen và cộng sự [5] đề xuất outcome/process efficiency metric và self-training để giảm overthinking. Trên MATH500, biến thể QwQ-32B-Preview giảm từ 2407.9 xuống 1330.7 token, trong khi accuracy đổi từ 93.0% thành 92.8%; tiết kiệm vì vậy có thể đi kèm mất hiệu năng. Ngược lại, Wang và cộng sự [24] chẩn đoán việc đổi liên tục giữa các hướng chưa được phát triển đủ sâu. Trên AIME 2024, TIP tăng Pass@1 của QwQ-32B-Preview từ 38.3% lên 44.1%, ước lượng từ 32 mẫu mỗi bài. Tổng trace dài vẫn có thể đi cùng độ sâu exploration không đủ.

**Peng và cộng sự** [20] phân tích overthinking qua hành vi *self-doubt*, tức kiểm tra lặp lại các kết luận trung gian đã đúng, như một nguồn tiêu token dư thừa quan trọng. Trên bài thiếu tiền đề, model không được hướng dẫn có thể sinh 4,700–6,400 token để cố chứng minh điều không thể. Prompt kiểm tra tiền đề giúp giảm 35%–45% token trong khi giữ hoặc tăng accuracy ở các model được thử.

## 2.4 Evaluation/Benchmark (A4)

Đánh giá Long-CoT cần benchmark kiểm tra state tracking qua horizon dài, metric tự động đo reasoning efficiency và giao thức process supervision.

### 2.4.1 Benchmark về dependency dài và giới hạn scaling

Để bổ sung cho benchmark ngắn đã bão hòa, **LongCoT** [18] cung cấp 2,500 bài sinh từ template tham số hóa do chuyên gia thiết kế, thuộc năm miền: toán, hóa, khoa học máy tính, cờ vua và logic hình thức. Độ dài lời giải thay đổi lớn, thường 10k–100k+ token. Trên 2,000 bài vừa/khó, frontier model được thử có accuracy thấp: `GPT-5.2` đạt 9.83%, `Gemini 3 Pro` 6.08%, `Grok 4.1` 2.04%. Trong thí nghiệm riêng tăng dependency DAG tuần tự từ 1 đến 35 node bài toán con, accuracy suy giảm nhanh hơn baseline lỗi độc lập ($p^N$), đặc biệt sau 15 node. Kết quả hỗ trợ giả thuyết của tác giả về sự suy giảm khả năng mang trạng thái qua context kéo dài.

**SPaRC** [9] đánh giá spatial planning nhiều bước qua câu đố tìm đường lưới 2D biểu diễn bằng văn bản, chia năm mức khó. Người giải đạt 98.0% tổng thể và 94.5% ở Level 5; reasoning model cao nhất được thử, `o4-mini`, đạt 15.8% tổng thể và 1.1% ở Level 5, với hơn 50% đường đi vi phạm luật di chuyển. SPaRC còn ghi nhận thiếu adaptive compute scaling: con người tăng thời gian suy nghĩ theo độ khó, trong khi `QwQ-32B` sinh lượng token gần nhau giữa các mức, 14,433 ở Level 1 và 13,114 ở Level 5.

### 2.4.2 Khung tự động đánh giá redundancy dựa trên graph

**CoTJudger** [14] đánh giá efficiency không cần nhãn người từng bước bằng cách chuyển trace thành directed dependency graph và tìm *Shortest Effective Path* (SEP). Phương pháp dùng forward depth-first search kết hợp LLM consistency judge. Redundancy Ratio được định nghĩa $R = (|V| - L_{\text{eff}})/|V|$, biểu thị tỷ lệ node/bước nằm ngoài SEP. Trên 21 reasoning model, nhiều node nằm ngoài SEP, tập trung trong các vòng self-verification sau khi đã có thể kết luận. SEP được xem là structural proxy phụ thuộc judge, không chứng minh mọi bước bị loại đều thừa về ngữ nghĩa. Tác giả cũng quan sát distilled model có logical density trên mỗi bước thấp hơn teacher.

### 2.4.3 Benchmark process supervision và critique ở cấp bước

**ProcessBench** [32] cung cấp 3,400 trường hợp với lời giải từng bước trên bốn subset GSM8K, MATH, OlympiadBench và Omni-MATH. Chuyên gia gán nhãn bước lỗi đầu tiên. So sánh Process Reward Model (PRM) chuyên biệt với LLM critic cho thấy PRM học trên dữ liệu đơn giản tổng quát hóa kém ở bài đa dạng: `Skywork-PRM-7B` đạt F1 trung bình 42.1% qua bốn

subset. Reasoning model được prompt làm critic có kết quả cao hơn: `QwQ-32B-Preview` đạt F1 trung bình 71.5%, vượt `GPT-4o` (61.9%) nhưng thấp hơn `o1-mini` (87.9%).

**CriticBench** [17] đánh giá ba năng lực Generation, Critique và Correction (GQC) trên năm miền suy luận. Trên 17 LLM, accuracy critique tương quan dương với khả năng correction sau đó; các model nhỏ có xu hướng dè dặt khi self-critique nếu không được hướng dẫn bằng external feedback.

### 2.5 Đối chiếu các chiến lược training và dữ liệu

Literature A1 hướng đến ít nhất hai mục tiêu khác nhau: hình thành hành vi deliberation hiệu quả và giảm chi phí của hành vi đã có. R1 và Kimi chủ yếu xây dựng quy trình training hướng capability; s1 và LIMO khảo sát khả năng kích hoạt năng lực với ít dữ liệu; Light-R1 nghiên cứu phát triển qua stage; efficiency-aware RL thay đổi trực tiếp objective accuracy–length. Điểm cao ở mục tiêu này chưa chứng minh cùng phương pháp là tốt nhất cho mục tiêu kia.

**Tập training nhỏ chứng minh điều gì?** Thiết lập s1K với 1,000 mẫu và LIMO với 817 mẫu là bằng chứng về post-training trên checkpoint mạnh cụ thể, không phải tổng chi phí xây một reasoning model [19, 29]. Chi phí teacher generation, filtering và pretraining vẫn liên quan. So sánh hữu ích cần giữ base checkpoint, prompt evaluation và decoding budget, rồi thay chất lượng lựa chọn dữ liệu ở cùng số mẫu. Với s1, training và budget forcing cũng cần ablation riêng; nếu không, gain được gán cho dataset có thể một phần đến từ inference control. Chỉ lấy điểm AIME giữa các paper chưa tạo được đối chứng như vậy.

**Sự hình thành hành vi qua RL chứng minh điều gì?** R1-Zero bỏ cold-start SFT trong thiết lập của nó, còn R1 hoàn chỉnh bổ sung các stage để tăng tính hữu dụng [6]. Phân biệt này tránh suy ra sai rằng model cuối chỉ dùng pure RL hoặc có tri thức mà không cần base mạnh. Tương tự, CoT-RM của Kimi sinh reasoning khi chấm độ đúng đáp án cuối; không nên nhầm với policy được training bằng nhãn người đúng/sai ở từng reasoning step [10]. Compute cho rollout và reward model phải được tính vào training cost.

| **Hướng A1** | **Đối chiếu cần thực hiện** | **Yếu tố gây nhiễu cần kiểm soát** |
|---|---|---|
| RL hướng capability | Cùng base, thay quy trình SFT/RL | Verifier, rollout budget, năng lực pretraining |
| SFT ít dữ liệu | Demonstration chọn lọc và ngẫu nhiên cùng số mẫu | Chất lượng teacher, filtering cost, decoding budget |
| Curriculum | Bỏ stage hoặc đổi thứ tự | Lượng dữ liệu, tổng training token, contamination |
| RL hướng efficiency | Frontier accuracy–cost so với cutoff/SFT/DPO | Độ khó tác vụ, hệ số độ dài, faithfulness |

Bảng 3: Các chiều đối chiếu đề xuất cho A1. Đây là tiêu chí đọc nghiên cứu, không phải kết quả thực nghiệm bổ sung.

**Chuyển giao và chuyên biệt hóa.** Gain qua các stage của Light-R1 cần được đọc cùng kết quả GPQA không tăng đơn điệu [26]. Curriculum có thể cải thiện miền đích mà không tăng đồng đều năng lực rộng hơn. Long2short và length-aware RL còn gợi nhu cầu báo cáo nhiều điểm đánh đổi accuracy–cost, thay vì chỉ một compressed model. Kết quả tối ưu lý tưởng của Arora và Zanette không bảo đảm training hữu hạn giữ nguyên accuracy hay faithfulness [1]. Vì vậy chúng tôi tách capability, data efficiency, inference efficiency và transfer thành các kết quả riêng.

## 2.6 Đối chiếu các inference controller

Một inference controller được mô tả bằng bốn thành phần: quan sát, quy tắc quyết định, action và chi phí phụ. Cách tách này phân biệt các phương pháp dùng chung trigger bề mặt nhưng dựa trên bằng chứng dừng khác nhau. Nó cũng phân biệt policy LLM training-free với hệ thống có một diagnostic component được training riêng.

**Quyết định dừng dưới uncertainty.** Sufficiency assessment của DTSR và redundancy detector của REFRAIN trả lời hai câu hỏi vận hành khác nhau [23, 27]. DTSR đánh giá phần suy luận đã đủ chưa; REFRAIN dùng tín hiệu reflection lặp lại để nhận diện lãng phí có thể có. REFRAIN điều chỉnh threshold bằng reward kết hợp answer-only likelihood và length penalty, không dùng ground-truth correctness của test. Bandit adaptation thay trạng thái controller, không thay trọng số LLM. Cả sufficiency lẫn likelihood đều là proxy có thể sai: suy luận tự tin nhưng thiếu bước có thể dừng sớm, còn verification hữu ích có thể trông giống lặp thừa.

**Sửa prefix khác với nối dài prefix.** TAAR loại đoạn bẫy được chẩn đoán trước khi restart; MCTSr phân bổ search trên các lời giải hoàn chỉnh được refine [3, 30]. Chỉ so path count sẽ bỏ qua khác biệt về độ dài và số lần gọi evaluator trên từng path. Với TAAR phải cộng prefix bị bỏ và các lượt chẩn đoán; với MCTSr phải cộng critique, rewrite, self-evaluation và nhánh thất bại. Kết quả TAAR kém hơn trên một model lớn được thử cũng cho thấy không nên mặc định restart luôn hữu ích.

| Controller | Quyết định và action | Failure mode cần xem xét |
|---|---|---|
| DTSR | Đánh giá sufficiency; kết thúc thinking | Dừng sớm và overhead đánh giá |
| REFRAIN | Phát hiện redundancy; thích ứng threshold | Nhầm similarity/likelihood với sufficiency |
| TAAR | Chẩn đoán trap; prune và restart | Bỏ prefix gần đúng |
| MCTSr | Chấm ứng viên; mở rộng/refine search | Self-evaluation lệch và search cost bị bỏ sót |
| Recursive Models | Cô lập local context; trả trạng thái subproblem | Mất điều kiện khi nén return value |
| Budget, TIP, FSF | Phân bổ độ dài, độ sâu exploration hoặc nhánh | Overthinking hoặc bám giữ nhánh sai |

Bảng 4: Đối chiếu A2 theo quyết định và failure mode. Paper được dẫn chéo giữ nguyên primary role.

**Memory, độ dài và độ sâu là các tài nguyên khác nhau.** Recursive Models giảm active context bằng local frame và return value [28]. Điều đó không đồng nghĩa toàn bộ thực thi sinh ít token hơn. Budget forcing điều tiết thời lượng; TIP hạn chế đổi hướng sớm; selection hoặc pruning theo FSF dùng bằng chứng cấu trúc [7, 19, 24]. Các action có thể bổ sung nhau, nhưng khả năng kết hợp vẫn là giả thuyết cần đánh giá chung. Một hệ thống có thể đồng thời có active context ngắn, tổng thực thi dài và exploration sâu ở một subproblem.

## 2.7 Diễn giải bằng chứng trong các paper Analysis

Claim phân tích cần gắn với đối tượng được đo và phép can thiệp. Văn bản trace, dependency graph được trích, correctness predictor được học và tính toán nội tại của generator là các đối tượng riêng. Thành công của phương pháp trên một đối tượng không tự giải thích những đối tượng còn lại.

| Loại bằng chứng | Có thể hỗ trợ kết luận | Vấn đề còn bỏ ngỏ |
|---|---|---|
| Quan sát trace | Liên hệ hành vi trong corpus được lấy mẫu | Chiều nhân quả và yếu tố gây nhiễu chưa quan sát |
| Dự đoán correctness | Feature hữu ích cho prediction hoặc selection | Feature có phải cơ chế nội tại không |
| Can thiệp trace | Độ nhạy với edit/continuation cụ thể | Distribution shift và generalization |
| Can thiệp nội tại | Dependency dưới perturbation đã chọn | Có tương đương dependency diễn ngôn không |

Bảng 5: Phân biệt bằng chứng trong A3. Các loại mô tả thiết kế nghiên cứu, không phải thứ hạng khiến mọi can thiệp đều cho kết luận chắc chắn.

**Biểu diễn và cơ chế.** ReasoningFlow cung cấp discourse schema và kiểm tra riêng mức alignment với dependency dựa trên can thiệp [13]. Kết quả alignment yếu cần giới hạn trong setup QwQ/AIME đã thử. GNNExplainer của CoT2Graph giải thích dự đoán của graph classifier, không trực tiếp giải thích cơ chế nhân quả của generator [2]. Correctness-prediction accuracy cũng khác accuracy của đáp án được predictor chọn. Chất lượng dựng graph, mức phụ thuộc judge và khả năng transfer qua model vì vậy là một phần của bằng chứng, không chỉ là chi tiết preprocessing có thể bỏ qua.

**Đối chiếu overthinking và underthinking.** Chen, Wang và Peng lần lượt khảo sát tính toán dư thừa, đổi hướng quá sớm và self-doubt [5, 20, 24]. Những chẩn đoán này có thể cùng xuất hiện trong một trace: model tiêu nhiều token lặp lại việc vào nhánh nông mà không phát triển nhánh nào đủ xa. Vì vậy suppress mọi reflection khác với loại một verification dư thừa hay trì hoãn một lần đổi hướng sớm. Can thiệp có ích với failure mode này có thể làm failure mode khác nặng hơn. Claim reasoning dài hơn có lợi hay hại cần chỉ rõ nội dung được thêm, vị trí thêm và compute budget được giữ cố định.

**Từ quan sát đến can thiệp có thể sử dụng.** Selection theo FSF giữ nguyên tập ứng viên, thay quy tắc chọn; branch editing thay prefix và quan sát continuation [7]. Thiết lập đầu chứng minh tính hữu ích khi chọn output; thiết lập sau kiểm tra tác động của một thay đổi context cụ thể. Cả hai không khiến mọi nhánh bị bỏ dở đều trở nên vô ích về ngữ nghĩa. Perturbation của Lanham và cộng sự cũng gợi nhu cầu matched control cho edit có thể lệch phân phối [11]. ZebraLogic bổ sung trục độ phức tạp riêng: tăng search space tổ hợp không phải cùng thao tác với tăng dependency horizon [16].

## 2.8 Đơn vị đánh giá, metric và so sánh công bằng

Chúng tôi tách final-answer correctness, process quality, efficiency và faithfulness. Đáp án cuối có thể đúng dù bước trung gian invalid; trace mạch lạc có thể bỏ sót yếu tố gây ra đáp án; trace ngắn có thể rẻ nhưng chưa đủ lập luận. Chưa có metric đơn lẻ trong danh mục thay thế được cả bốn chiều.

**Đơn vị của benchmark.** LongCoT có tập template đa miền và một thí nghiệm riêng thay đổi dependency DAG; không nên trộn kích thước dataset và trục thao tác của chúng [18]. SPaRC cho phép kiểm tra path validity và phân bổ compute theo độ khó [9]. Điểm thấp trong các họ tác vụ này chỉ ra giới hạn trong stress test, không phải sự bất lực suy luận tổng quát. Với CoTJudger, đơn vị redundancy là node/bước được trích, không phải token [14]. Đổi segmentation có thể đổi cả mẫu số lẫn shortest path. Bước ngoài path vẫn có thể giúp tìm hoặc kiểm tra lời giải.

**F1 theo giao thức riêng của ProcessBench.** ProcessBench yêu cầu tìm bước lỗi đầu tiên hoặc quyết định no-error, không yêu cầu sinh lời giải mới [32]. Gọi $a_{\text{err}}$ là accuracy trên mẫu có lỗi và $a_{\text{ok}}$ là accuracy trên mẫu đúng. Score được báo cáo là harmonic mean:

$$F_{\text{PB}} = \frac{2a_{\text{err}}a_{\text{ok}}}{a_{\text{err}} + a_{\text{ok}}}. \tag{2}$$

Không nên mô tả score này là binary F1 thông thường ở cấp token hoặc bước. Trung bình theo subset cũng phải phân biệt với accuracy gộp mẫu. CriticBench bổ sung cho error localization bằng cách tách generation, critique và correction [17]; critic tìm đúng lỗi chưa chắc tạo feedback giúp sửa được lỗi.

**Sampling và cách tính compute.** Pass@1 được ước lượng từ nhiều mẫu vẫn đo xác suất thành công kỳ vọng của một lần thử. Nó khác với thành công trong ít nhất một trong $k$ lần thử. Khi áp dụng được, estimator dựa trên mẫu thường dùng là:

$$\widehat{\text{pass@}k} = 1 - \frac{\binom{n-c}{k}}{\binom{n}{k}}, \tag{3}$$

trong đó $c$ trong $n$ output được lấy mẫu là đúng. Không được đổi tên mean accuracy qua $k$ mẫu thành Pass@$k$. Bản tổng hợp giữ estimator và sampling setting của từng nguồn. Để so hệ thống, nhóm đề xuất báo cáo tổng chi phí generation, judge/verifier, checking, parsing, nhánh bị bỏ và restart, cùng latency và peak active context. Đây là khuyến nghị báo cáo; không phải paper nào cũng đo đủ các thành phần.

Chênh lệch điểm nhỏ cần uncertainty estimate trước khi tuyên bố ưu thế hay tương đương. Checkpoint, prompt, dataset split, ngày model API và chính sách contamination cần đi cùng điểm chính. Cùng path count không có nghĩa cùng token/FLOP cost; cùng output token không có nghĩa cùng latency toàn hệ thống.

## 2.9 Câu hỏi nghiên cứu liên vai trò

Các câu hỏi sau là thí nghiệm đề xuất từ literature đã đọc. Chúng chưa được thực hiện trong repo và bản survey không khẳng định kết quả của chúng.

1. **Học capability mới hay kích hoạt capability sẵn có?** Giữ base và training-token budget, thay demonstration được chọn lọc và quy trình RL. So độ khó held-out, transfer và chi phí sinh dữ liệu để phân biệt lợi ích của checkpoint mạnh hơn với post-training tốt hơn.

2. **Learned efficiency có kết hợp được với stopping?** Đánh giá thiết kế $2 \times 2$: có/không efficiency training và có/không controller. Báo frontier accuracy–cost, checking cost và tỷ lệ early exit biến đáp án đúng của full run thành sai.

3. **Khi nào reflection hữu ích?** Từ các prefix tương ứng, tiếp tục bình thường, suppress hoặc khuyến khích reflection dưới budget tương ứng. Tách repair gain khỏi việc sửa hỏng đáp án đã đúng, thay vì chỉ đếm reflection token.

4. **Graph metric có ổn định khi đổi extractor?** Parse cùng trace bằng nhiều judge và một subset gán nhãn người. So structural agreement, thứ hạng metric, chất lượng selection và judge cost.

5. **Failure do horizon hay độ phức tạp tổ hợp?** Thay dependency depth độc lập với branching/search difficulty. Báo accuracy theo hai chiều và lỗi state validity, thay vì xem mọi output dài là khó như nhau.

6. **Khi nào hệ thống nên restart?** Trên cùng prefix và tổng budget, so continuation, restart và targeted pruning. Đo escape probability, tỷ lệ bỏ prefix đúng và accuracy ròng.

7. **Compression có thay đổi faithfulness?** Dùng hint và trace perturbation tương ứng trước/sau compression, có đối chứng distribution shift. Báo answer accuracy cùng faithfulness proxy được định nghĩa rõ.

8. **Verifier có transfer sang horizon dài hơn?** Giữ loại lỗi, tăng trace length và khoảng cách đến lỗi đầu tiên. Đánh giá localization, no-error accuracy, calibration và latency mà không tune threshold trên test.

Các câu hỏi nối objective của A1, quyết định A2, bằng chứng giải thích A3 và phép đo A4. Mục tiêu là làm phép so sánh tiếp theo có thể kiểm chứng, không mặc định một phương pháp hay taxonomy giải quyết mọi failure của Long-CoT.

## Tài liệu


[1] Daman Arora and Andrea Zanette. Training language models to reason efficiently. *arXiv preprint arXiv:2502.04463*, 2025. URL https://arxiv.org/abs/2502.04463v4.

[2] Tommaso Felice Banfi, Mubashara Akhtar, Jingwei Ni, and Mrinmaya Sachan. Understanding failures in LLM reasoning by learning structured representations of chain-of-thought. *OpenReview preprint forum:wFTJZ8fvns*, 2026. URL https://openreview.net/forum?id=wFTJZ8fvns. Author-reported Findings of EMNLP 2026.

[3] Kang Chen, Fan Yu, Junjie Nian, Shihan Zhao, Zhuoka Feng, Zijun Yao, Heng Wang, Minshen Yu, and Yixin Cao. Thinking traps in long chain-of-thought: A measurable study and trap-aware adaptive restart. *arXiv preprint arXiv:2601.11940*, 2026. URL https://arxiv.org/abs/2601.11940v1. Author-reported Findings of ACL 2026.

[4] Qiguang Chen, Libo Qin, Jinhao Liu, Dengyun Peng, Jiannan Guan, Peng Wang, Mengkang Hu, Yuhang Zhou, Te Gao, and Wanxiang Che. Towards reasoning era: A survey of long chain-of-thought for reasoning large language models. *arXiv preprint arXiv:2503.09567*, 2025. URL https://arxiv.org/abs/2503.09567v5.

[5] Xingyu Chen, Jiahao Xu, Tian Liang, Zhiwei He, Jianhui Pang, Dian Yu, Linfeng Song, Qiuzhi Liu, Mengfei Zhou, Zhuosheng Zhang, Rui Wang, Zhaopeng Tu, Haitao Mi, and Dong Yu. Do NOT think that much for 2+3=? on the overthinking of o1-like LLMs. *arXiv preprint arXiv:2412.21187*, 2024. URL https://arxiv.org/abs/2412.21187v2. Version 2, February 2025.

[6] DeepSeek-AI. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025. URL https://arxiv.org/abs/2501.12948v2.

[7] Yunzhen Feng, Julia Kempe, Cheng Zhang, Parag Jain, and Anthony Hartshorn. What characterizes effective reasoning? revisiting length, review, and structure of CoT. *arXiv preprint arXiv:2509.19284*, 2025. URL https://arxiv.org/abs/2509.19284v1.

[8] Yixin Ji, Juntao Li, Yang Xiang, Hai Ye, Kaixin Wu, Kai Yao, Jia Xu, Linjian Mo, and Min Zhang. A survey of test-time compute: From intuitive inference to deliberate reasoning. *arXiv preprint arXiv:2501.02497*, 2025. URL https://arxiv.org/abs/2501.02497v3.

[9] Lars Benedikt Kaesberg, Jan Philip Wahle, Terry Ruas, and Bela Gipp. SPaRC: A spatial pathfinding reasoning challenge. *arXiv preprint arXiv:2505.16686*, 2025. URL https://arxiv.org/abs/2505.16686v2. Author-reported EMNLP 2025.

[10] Kimi Team. Kimi k1.5: Scaling reinforcement learning with LLMs. *arXiv preprint arXiv:2501.12599*, 2025. URL https://arxiv.org/abs/2501.12599v4.

[11] Tamera Lanham, Anna Chen, Ansh Radhakrishnan, Benoit Steiner, Carson Denison, Danny Hernandez, Dustin Li, Esin Durmus, Evan Hubinger, Jackson Kernion, Kamile Lukosiute, Karina Nguyen, Newton Cheng, Nicholas Joseph, Nicholas Schiefer, Oliver Rausch, Robin Larson, Sam McCandlish, Sandipan Kundu, Saurav Kadavath, Shannon Yang, Thomas Henighan, Timothy Maxwell, Timothy Telleen-Lawton, Tristan Hume, Zac Hatfield-Dodds, Jared Kaplan, Jan Brauner, Samuel R. Bowman, and Ethan Perez. Measuring faithfulness in chain-of-thought reasoning. *arXiv preprint arXiv:2307.13702*, 2023. URL https://arxiv.org/abs/2307.13702v1.

[12] Jinu Lee and Julia Hockenmaier. Evaluating step-by-step reasoning traces: A survey. *arXiv preprint arXiv:2502.12289*, 2025. URL https://arxiv.org/abs/2502.12289v3. Author-reported EMNLP 2025 Findings.

[13] Jinu Lee, Shivam Agarwal, Amruta Parulekar, Siddarth Madala, Dilek Hakkani-T"ur, and Julia Hockenmaier. ReasoningFlow: Discourse structures for understanding LLM reasoning traces. *arXiv preprint arXiv:2606.05402*, 2026. URL https://arxiv.org/abs/2606.05402v2. Author-reported EMNLP 2026 Oral.

[14] Siyi Li, Jiajun Shi, Shiwen Ni, Ge Zhang, Shuaimin Li, Shijian Wang, Zhoufutu Wen, Yizhi Li, Hamid Alinejad-Rokny, Jiaheng Liu, Min Yang, and Wenhao Huang. CoT-Judger: A graph-driven framework for automatic evaluation of chain-of-thought efficiency and redundancy in LRMs. *arXiv preprint arXiv:2603.07078*, 2026. URL https://arxiv.org/abs/2603.07078v1. Author-reported ACL 2026 Main Conference.

[15] Zhong-Zhi Li, Duzhen Zhang, Ming-Liang Zhang, Jiaxin Zhang, Zengyan Liu, Yuxuan Yao, Haotian Xu, Junhao Zheng, Pei-Jie Wang, Xiuyi Chen, Yingying Zhang, Fei Yin, Jiahua Dong, Zhiwei Li, Bao-Long Bi, Ling-Rui Mei, Junfeng Fang, Xiao Liang, Zhijiang Guo, Le Song, and Cheng-Lin Liu. From system 1 to system 2: A survey of reasoning large language models. *arXiv preprint arXiv:2502.17419*, 2025. URL https://arxiv.org/abs/2502.17419v6.

[16] Bill Yuchen Lin, Ronan Le Bras, Kyle Richardson, Ashish Sabharwal, Radha Poovendran, Peter Clark, and Yejin Choi. ZebraLogic: On the scaling limits of LLMs for logical reasoning. *arXiv preprint arXiv:2502.01100*, 2025. URL https://arxiv.org/abs/2502.01100v2. Author-reported ICML 2025.

[17] Zicheng Lin, Zhibin Gou, Tian Liang, Ruilin Luo, Haowei Liu, and Yujiu Yang. CriticBench: Benchmarking LLMs for critique-correct reasoning. *arXiv preprint arXiv:2402.14809*, 2024. URL https://arxiv.org/abs/2402.14809v4. Author-reported Findings of ACL 2024.

[18] Sumeet Ramesh Motwani, Daniel Nichols, Charles London, Peggy Li, Fabio Pizzati, Acer Blake, Hasan Hammoud, Tavish McDonald, Akshat Naik, Alesia Ivanova, Vignesh Baskaran, Ivan Laptev, Ruben Glatt, Tal Ben-Nun, Philip Torr, Natasha Jaques, Ameya Prabhu, Brian Bartoldson, Bhavya Kailkhura, and Christian Schroeder de Witt. LongCoT: Benchmarking long-horizon chain-of-thought reasoning. *arXiv preprint arXiv:2604.14140*, 2026. URL https://arxiv.org/abs/2604.14140v1. Author-reported ICML 2026.

[19] Niklas Muennighoff, Zitong Yang, Weijia Shi, Xiang Lisa Li, Fei-Fei Li, Hannaneh Hajishirzi, Luke Zettlemoyer, Percy Liang, Emmanuel Candès, and Tatsunori Hashimoto. s1: Simple test-time scaling. *arXiv preprint arXiv:2501.19393*, 2025. URL https://arxiv.org/abs/2501.19393v3.

[20] Keqin Peng, Liang Ding, Yuanxin Ouyang, Meng Fang, and Dacheng Tao. Revisiting overthinking in long chain-of-thought from the perspective of self-doubt. *arXiv preprint arXiv:2505.23480*, 2025. URL https://arxiv.org/abs/2505.23480v1.

[21] Xiaoye Qu, Yafu Li, Zhao-Chen Su, Weigao Sun, Jianhao Yan, Dongrui Liu, Ganqu Cui, Daizong Liu, Shuxian Liang, Junxian He, Peng Li, Wei Wei, Jing Shao, Chaochao Lu, Yue Zhang, Xian-Sheng Hua, Bowen Zhou, and Yu Cheng. A survey of efficient reasoning for large reasoning models: Language, multimodality, and beyond. *arXiv preprint arXiv:2503.21614*, 2025. URL https://arxiv.org/abs/2503.21614v2.

[22] Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen Zhong, Na Zou, Hanjie Chen, and Xia Hu. Stop

overthinking: A survey on efficient reasoning for large language models. *arXiv preprint arXiv:2503.16419*, 2025. URL https://arxiv.org/abs/2503.16419v4.

[23] Renliang Sun, Wei Cheng, Dawei Li, Haifeng Chen, and Wei Wang. Stop when enough: Adaptive early-stopping for chain-of-thought reasoning. *arXiv preprint arXiv:2510.10103*, 2025. URL https://arxiv.org/abs/2510.10103v1.

[24] Yue Wang, Qiuzhi Liu, Jiahao Xu, Tian Liang, Xingyu Chen, Zhiwei He, Linfeng Song, Dian Yu, Juntao Li, Zhuosheng Zhang, Rui Wang, Zhaopeng Tu, Haitao Mi, and Dong Yu. Thoughts are all over the place: On the underthinking of o1-like LLMs. *arXiv preprint arXiv:2501.18585*, 2025. URL https://arxiv.org/abs/2501.18585v2.

[25] Jiaqi Wei, Xiang Zhang, Yuejin Yang, Wenxuan Huang, Juntai Cao, Sheng Xu, Xiang Zhuang, Zhangyang Gao, Muhammad Abdul-Mageed, Laks V. S. Lakshmanan, Chenyu You, Wanli Ouyang, and Siqi Sun. When LLM meets tree search: A systematic view of inference as search in large language models. *arXiv preprint arXiv:2608.30395*, 2026. URL https://arxiv.org/abs/2608.30395v1. Author-reported EMNLP 2026 Findings.

[26] Liang Wen, Yunke Cai, Fenrui Xiao, Xin He, Qi An, Zhenyu Duan, Yimin Du, Junchen Liu, Lifu Tang, Xiaowei Lv, Haosheng Zou, Yongchao Deng, Shousheng Jia, and Xiangzheng Zhang. Light-R1: Curriculum SFT, DPO and RL for long COT from scratch and beyond. *arXiv preprint arXiv:2503.10460*, 2025. URL https://arxiv.org/abs/2503.10460v4. Author-reported ACL 2025 Industry Track.

[27] Yang Xiang, Yixin Ji, Ruotao Xu, Dan Qiao, Zheming Yang, Juntao Li, and Min Zhang. When is thinking enough? early exit via sufficiency assessment for efficient reasoning. *arXiv preprint arXiv:2604.06787*, 2026. URL https://arxiv.org/abs/2604.06787v1. Author-reported ACL 2026 Main Conference.

[28] Chenxiao Yang, Nathan Srebro, and Zhiyuan Li. Recursive models for long-horizon reasoning. *arXiv preprint arXiv:2603.02112*, 2026. URL https://arxiv.org/abs/2603.02112v2. Author-reported ICML 2026.

[29] Yixin Ye, Zhen Huang, Yang Xiao, Ethan Chern, Shijie Xia, and Pengfei Liu. LIMO: Less is more for reasoning. *arXiv preprint arXiv:2502.03387*, 2025. URL https://arxiv.org/abs/2502.03387v3.

[30] Di Zhang, Xiaoshui Huang, Dongzhan Zhou, Yuqiang Li, and Wanli Ouyang. Accessing GPT-4 level mathematical olympiad solutions via Monte Carlo tree self-refine with LLaMa-3 8b. *arXiv preprint arXiv:2406.07394*, 2024. URL https://arxiv.org/abs/2406.07394v2.

[31] Qiyuan Zhang, Fuyuan Lyu, Zexu Sun, Lei Wang, Weixu Zhang, Wenyue Hua, Haolun Wu, Zhihan Guo, Yufei Wang, Niklas Muennighoff, Irwin King, Xue Liu, and Chen Ma. A survey on test-time scaling in large language models: What, how, where, and how well? *arXiv preprint arXiv:2503.24235*, 2025. URL https://arxiv.org/abs/2503.24235v3.

[32] Chujie Zheng, Zhenru Zhang, Beichen Zhang, Runji Lin, Keming Lu, Bowen Yu, Dayiheng Liu, Jingren Zhou, and Junyang Lin. ProcessBench: Identifying process errors in mathematical reasoning. *arXiv preprint arXiv:2412.06559*, 2025. URL https://arxiv.org/abs/2412.06559v4. Author-reported ACL 2025 Main Conference.

[33] Jason Zhu and Hongyu Li. Towards concise and adaptive thinking in large reasoning models: A survey. *arXiv preprint arXiv:2507.09662*, 2025. URL https://arxiv.org/abs/2507.09662v1.